Wojciech Celej 271248 piątek 12

Sprawozdanie z laboratorium BD: 10, 11, 12 Indeksy, hinty

1. Indeksy - scan

Tabela WAREHOUSE – zawiera spis wszystkich magazynów magazynach:

Atrybuty: WAREHOUSE_ID (klucz główny), CITY (VARCHAR 25 bajtów), CAPACITY(INTEGER), STREET(VARCHAR 500 bajtów)
Tablicę wypełniono 1000 rekordów, losowymi wartościami. Atrybut CAPACITY przyjmuje wartości od 10 do 1000. Atrybut STREET wypełniono stringami o długości 400 bajtów w celu zapełnienia dysku.

Zapytania:

SELECT * FROM WAREHOUSE WHERE CAPACITY <200;

Selektywność takiego zapytana jest rzędu 20%

Wyniki bez użycia indeksu na CAPACITY: 66 (niezależne od selektywności)

Wyniki z użyciem indeksu na CAPACITY:



SELECT * FROM WAREHOUSE WHERE CAPACITY <20;

Selektywność takiego zapytania jest rzędu 1%.

Wyniki bez użycia indeksu na CAPACITY:



Wyniki z użyciem indeksu na CAPACITY:

OPERATION	OBJECT_NAME	OPTIONS	CARDINALITY	COST	
■ SELECT STATEMENT				5	8
TABLE ACCESS	WAREHOUSE	BY INDEX ROWID		5	8
□ □ □ INDEX	WARHOUSE_CAPACITY	RANGE SCAN		5	2
Access Predicates					

SELECT * FROM WAREHOUSE WHERE CAPACITY=100; (selektywność 0.1%)

Wyniki z użyciem indeksu na CAPACITY:

OPERATION	OBJECT_NAME	OPTIONS	CARDINALITY	COST	
■ SELECT STATEMENT				2	3
TABLE ACCESS	WAREHOUSE	BY INDEX ROWID		2	3
□ □를 INDEX	WARHOUSE CAPACITY	RANGE SCAN		2	1

Tabela ARTICLE – spis wszystkich dostępnych artykułów

Atrybuty: ARTICLE_ID (klucz główny), ART_NAME (VARCHAR 50 bajtów), CATEGORY (VARCHAR 1000 bajtów), VALUE (INTEGER)

Tablicę wypełniono liczbą 10000 rekordów, losowymi wartościami. Atrybut VALUE przyjmuje wartości od 10 do 1000. Atrybut CATEGORY wypełniono stringami o długości 800 bajtów w celu zapełnienia dysku.

Zapytania:

SELECT * FROM ARTICLE WHERE VALUE<200;

Selektywność takiego zapytania jest rzędu 20%

Bez indeksu na VALUE:

OPERATION	OBJECT_NAME	OPTIONS	CARDINALITY	COST	
■ SELECT STATEMENT				6238	966
TABLE ACCESS	ARTICLE	FULL		6238	966
Filter Predicates					

Z użyciem indeksu:

OPERATION	OBJECT_NAME	OPTIONS	CARDINALITY	COST	
■ SELECT STATEMENT				596	603
TABLE ACCESS	ARTICLE	BY INDEX ROWID		596	603
□ 0€ INDEX	ARTICLE_VALUE	RANGE SCAN		596	7

SELECT * FROM ARTICLE WHERE VALUE<20;

Selektywność takiego zapytania jest rzędu 1%

Bez indeksu na VALUE: uzyskano taki sam koszt jak poprzednio

Z użyciem indeksu:



Select * FROM ARTICLE WHERE VALUE=100;

Selektywność takiego zapytania jest rzędu 0.1%

Bez użycia indeksu na VALUE: uzyskano taki samo koszt jak poprzednio

Z użyciem indeksu:

VALUE-100



Posumowanie

W celu wymuszenia użycia indeksów zastosowano hinty: SELECT /*+ INDEX(tabName) */ * ...

W celu wymuszenia pełnego skanu użyto: SELECT /*+ FULL(tabName) */ * ...

Wyniki dla zastosowania SELECT /*+ INDEX_FFS(tabName) */ * ... będą przedstawione bezpośrednio w tabeli

WAREHOUSE

Selektywność	0.1%	1%	20%
FULL	66	66	66
INDEX	3	8	98
INDEX_FFS	3	8	66

ARTICLE

Selektywność	0.1%	1%	20%
FULL	966	966	966
INDEX	12	34	603
INDEX_FFS	12	34	603

Wnioski

- dla tabeli WAREHOUSE pokazano, że wymuszenie użycia indeksu spowodowało pogorszenie kosztów dostępu (aż o 50%) – optymalizator zapytań ORACLE nie używał indeksu, został on wymuszony
- w analogicznej sytuacji dla tabeli ARTICLE udało się obniżyć koszt zapytania o ok.
 35%, jak widać pogorszenie nie jest regułą
- niezależenie od selektywności, koszt zapytania bez użycia indeksu pozostaje stały
- dzięki użyciu indeksu, wraz ze spadkiem selektywności, koszt zapytania znacząco maleje
- proporcja kosztu zapytania bez użycia indeksu do analogicznego z zastosowaniem indeksu (czyli de facto proporcjonalny zysk) znacząco rośnie wraz ze spadkiem selektywności
- użycie indeksów ma najwięcej sensu dla zapytań o selektywności <10%

2. Indeksy - join

Zapytanie 1.

SELECT * FROM WAREHOUSE INNER JOIN WAREHOUSE_ARTICLE ON WAREHOUSE_ID=WAREHOUSE_WAREHOUSE_ID;

Tabela WAREHOUSE_ARTICLE zawiera 12000 rekordów. Przechowuje ona dane odnośnie artykułów przechowywanych w magazynach WAREHOUSE. W każdym magazynie znajduje się średnio 10 artykułów.

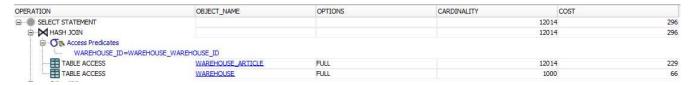
Nested loop join – jako hinta użyto /*+ USE_NL(WAREHOUSE, WAREHOUSE_ARTICLE)
 */

OPERATION	OBJECT NAME	OPTIONS	CARDINALITY	COST	
☐ SELECT STATEMENT				12014	11068
				12014	11068
TABLE ACCESS	WAREHOUSE	FULL		1000	66
⊟ od INDEX	WAREHOUSE_ARTICLE_PK	RANGE SCAN		12	1
WAREHOUSE_ID=W	AREHOUSE_WAREHOUSE_ID				
TABLE ACCESS	WAREHOUSE_ARTICLE	BY INDEX ROWID		12	11

 Sort-merge join - jako hinta użyto /*+ USE_MERGE(WAREHOUSE, WAREHOUSE_ARTICLE) */

OPERATION	OBJECT_NAME	OPTIONS	CARDINALITY	COST
■ SELECT STATEMENT			12014	298
			12014	298
		JOIN	1000	67
TABLE ACCESS	WAREHOUSE	FULL	1000	66
		JOIN	12014	231
Filter Predicates	EHOUSE_WAREHOUSE_ID			
	EHOUSE_WAREHOUSE_ID	Access of		
TABLE ACCESS	WAREHOUSE_ARTICLE	FULL	12014	229

3. Hash join - jako hinta użyto /*+ USE MERGE(WAREHOUSE, WAREHOUSE ARTICLE) */



Zapytanie 2.

SELECT * FROM ARTICLE INNER JOIN WAREHOUSE_ARTICLE ON ARTICLE_ID=ARTICLE_ARTICLE_ID WHERE VALUE<500;

1. Nested loop join - jako hinta użyto /*+ USE_NL(ARTICLE, WAREHOUSE_ARTICLE) */

OPERATION	OBJECT_NAME	OPTIONS	CARDINALITY	COST
■ SELECT STATEMENT			2626	12246
□ NESTED LOOPS				
□ M NESTED LOOPS			2626	12246
TABLE ACCESS	WAREHOUSE_ARTICLE	FULL	12014	229
□ □ INDEX	ARTICLE_PK	UNIQUE SCAN	1	. 0
ARTICLE_ID=ARTIC	CLE_ARTICLE_ID			
TABLE ACCESS	ARTICLE	BY INDEX ROWID	ai ei	1

2. Sort-merge join - jako hinta użyto /*+ USE_MERGE(ARTICLE, WAREHOUSE_ARTICLE)

OPERATION OPTIONS CARDINALITY OBJECT_NAME SELECT STATEMENT 1470 2626 MERGE JOIN 2626 1470 □ 4 SORT JOIN 1536 1239 TABLE ACCESS ARTICLE FULL 1536 966 ☐ **O** Filter Predicates ARTICLE.VALUE<500 JOIN

3. Hash join - jako hinta użyto /*+ USE_MERGE(ARTICLE, WAREHOUSE_ARTICLE) */

OPERATION	OBJECT_NAME	OPTIONS	CARDINALITY	COST	
□ SELECT STATEMENT				2626	1196
- MASH JOIN				2626	1196
Access Predicates ARTICLE_ID=ARTICLE_ARTICLE_ID TABLE ACCESS	WAREHOUSE_ARTICLE	FULL		12014	229
TABLE ACCESS	ARTICLE	FULL		1536	966
Filter Predicates ARTICLE.VALUE < 500					

Zapytanie 3.

SELECT VEHICLE.CAR_BRAND, VEHICLE.CAR_MODEL, VEHICLE.REGISTRATION_NUMBER, VEHICLE.DATE_OF_PRODUCTION, REPAIR.DATE_OF_START, REPAIR.DATE_OF_END, REPAIR.VALUE FROM REPAIR INNER JOIN VEHICLE ON REPAIR.VEHICLE_VEHICLE_ID=VEHICLE.VEHICLE_ID

Tabele VEHICLE i REPAIR mają po kilka rekordów. Na przykładzie takie złączenia pokazany zostanie sens użycia w niektórych przypadkach algorytmu nested loop join.

1. Nested loop join



2. Sort-merge join



3. Hash join

OPERATION	OBJECT_NAME	OPTIONS	CARDINALITY	COST	
■ SELECT STATEMENT				8	5
				8	5
	E_ID=VEHICLE.VEHICLE_ID				
TABLE ACCESS	VEHICLE	FULL		3	2
TABLE ACCESS	REPAIR	FULL		8	2

Podsumowanie

	Zapytanie 1.	Zapytanie 2.	Zapytanie 3.
Nested loop join	11068	12246	4
Sort-merge join	298	1470	5
Hash join	296	1196	5

Wnioski

- w zapytaniach 1. i 2. najgorsze wyniki uzyskano używając algorytmu nested loop join.
- w zapytaniach 1. i 2. najlepsze wyniki uzyskano stosując algorytm hash join.
- algorytm nested loop join jest zdecydowanie najwolniejszy dla dużych danych, ponieważ nie korzysta z żadnych informacji o porównywanych atrybutach – są to po prostu dwie zagnieżdżone pętle
- algorytm sort-merge join działa na dwóch posortowanych atrybutach, łącząc je w pętli; dzięki temu, że warunek łączenia założony był na atrybutach klucza głównego (które domyślnie posiadają index) łączenie tym algorytmem okazało się niewiele gorsze od hash join.
- algorytm hash join jest wybierany domyślnie przez optymalizator zapytań i sprawdza się również w wypadku, gdy dane nie są posortowane.
- algorytm nested loop join ma sens użycia jedynie w przypadku małej liczby danych, co pokazano na przykładzie zapytania 3. z małą liczbą danych
- dla zapytań operujących na małych zasobach danych względna różnica algorytmów jest niewielka